

Formulações de Programação Linear Inteira para o Problema de Alocação Mínima de Estações de Recarga

Eliel Lucas de Oliveira Carvalho

Universidade Estadual de Campinas, Instituto de Computação
Av. Albert Einstein, 1251 - Cidade Universitária, Campinas - SP, 13083-889
e295745@dac.unicamp.br

Santiago V. Ravelo

Universidade Estadual de Campinas, Instituto de Computação
Av. Albert Einstein, 1251 - Cidade Universitária, Campinas - SP, 13083-889
ravelo@unicamp.br

RESUMO

Este trabalho estuda uma variante do Problema de Alocação Mínima de Estações de Recarga (MIN-STATION) e uma generalização dessa variante. No problema considerado, busca-se determinar um conjunto mínimo de vértices intermediários para instalação de estações de recarga que permita conduzir robôs não rotulados, com autonomia limitada, de um conjunto de origens a um conjunto de destinos. O problema é recente, NP-difícil em grafos gerais e ainda não tratado por meio de Programação Linear Inteira (PLI). Propõe-se uma formulação base em PLI, baseada em fluxo em um dígrafo de alcance. Em seguida, apresenta-se uma formulação para uma generalização que incorpora custos de instalação, autonomias heterogêneas e critérios de elegibilidade entre origens e destinos. Nos experimentos, a formulação generalizada é parametrizada para representar a versão base, permitindo comparar o desempenho das duas formulações em redes de transporte.

PALAVRAS CHAVE. MIN-STATION, Programação Linear Inteira, Robôs móveis, Estações de recarga.

Tópicos: OD - Otimização Discreta; TAG - Teoria dos Grafos e Algoritmos Relacionados.

RESUMO

This paper studies a variant of the Minimum Charging Station Placement problem (MIN-STATION) and a generalization of this variant. In the problem considered, the goal is to determine a minimum set of intermediate vertices for installing charging stations, so that unlabeled robots with limited autonomy can be routed from a set of origins to a set of destinations. The problem is recent, NP-hard on general graphs, and has not yet been addressed through Integer Linear Programming (ILP). We propose a base ILP formulation based on flow over a reachability digraph. Then, we present a formulation for a generalized version of the problem, incorporating installation costs, heterogeneous robot ranges, and origin-destination eligibility criteria. In the computational experiments, the generalized formulation is parameterized to represent the base version, allowing the performance of the two formulations to be compared on transportation networks.

KEYWORDS. MIN-STATION, Integer Linear Programming, Mobile Robots, Charging Stations.

Topics: DO - Discrete Optimization; GTA - Graph Theory and Related Algorithms.

1. Introdução

O planejamento de tarefas e movimento para múltiplos robôs é um tema relevante na robótica móvel, em que diversos agentes precisam coordenar tarefas e deslocamentos em um mesmo ambiente. Esses sistemas são aplicados em áreas como logística, transporte autônomo, inspeção e vigilância, onde a cooperação entre os robôs é essencial. Nesses cenários, a eficiência da operação depende tanto da definição das rotas quanto da estratégia de alocação e coordenação dos robôs para o cumprimento dos objetivos propostos [Antonyshyn et al., 2023].

Uma limitação importante desses sistemas é a autonomia limitada das baterias. Em muitos cenários, os robôs não conseguem completar a missão com apenas uma carga, o que exige o planejamento de paradas para recarga. Assim, a existência de um caminho entre a origem e o destino não garante a viabilidade do deslocamento, já que o trajeto depende de a distância percorrida entre recargas consecutivas respeitar o limite de autonomia disponível [Strimel e Veloso, 2014].

Nesse contexto, o posicionamento das estações de recarga é importante para a continuidade operacional. Com o posicionamento estratégico dessas estações, é possível que os robôs restaurem sua autonomia durante a execução das tarefas, evitando falhas por esgotamento de bateria. Entretanto, considerando o custo de instalação dessas infraestruturas, existe a necessidade de minimizar o número de pontos de recarga sem comprometer as atividades dos robôs [Kundu e Saha, 2018, 2023].

Essa necessidade tem motivado diferentes abordagens para o posicionamento de estações de recarga para robôs móveis. Kundu e Saha [2018] estudaram a determinação do número e da localização das estações em um ambiente controlado e, posteriormente, propuseram algoritmos de aproximação para o problema em um grafo de movimento dos robôs [Kundu e Saha, 2023]. Castro-Gama e Hassink-Mulder [2023] formularam um modelo de Programação Linear Inteira (PLI) para minimizar o número de estações em uma rede, garantindo que seus pontos sejam atendidos dentro de um limite de distância associado à autonomia dos robôs. Por sua vez, Vichitkunakorn et al. [2024] consideraram conjuntamente a localização de estações e o roteamento de uma frota de drones com capacidade limitada de bateria.

É nesse contexto que se insere o Problema de Alocação Mínima de Estações de Recarga (MIN-STATION), definido por Das [2025]. Uma diferença central em relação às abordagens mencionadas anteriormente é que, no MIN-STATION, nem o pareamento entre origens e destinos nem as rotas dos robôs são definidos previamente. O problema considera um grafo simples, não direcionado e conexo $G = (V, E)$, um conjunto S de posições iniciais, um conjunto T de destinos, com $|S| = |T|$, e um parâmetro de autonomia r , que representa a distância máxima que um robô pode percorrer com uma única carga de bateria, antes de alcançar um ponto de recarga ou o destino. Os robôs são não rotulados, de modo que qualquer robô pode ser associado a qualquer destino. O objetivo consiste em determinar o menor conjunto de vértices para instalação de estações de recarga, garantindo que todos os destinos sejam alcançados sem que a distância percorrida entre recargas consecutivas exceda r .

Neste trabalho, é considerada uma variante do MIN-STATION em que os locais candidatos à instalação de estações de recarga são restritos aos vértices intermediários, isto é, aos vértices que não pertencem aos conjuntos de origens e destinos. Essa escolha separa as posições associadas ao início e ao término das tarefas dos pontos candidatos à instalação da infraestrutura de recarga.

O MIN-STATION é um problema recente e computacionalmente difícil. Das [2025] demonstrou que o problema é NP-difícil em grafos gerais e apresentou algoritmos exatos para classes específicas de grafos, como caminhos e ciclos. Entretanto, ainda não foram exploradas formulações em PLI para resolver o MIN-STATION. Essa lacuna motiva a investigação de modelos matemáticos capazes de representar o problema e permitir sua solução por meio de *solvers* de otimização.

Diante disso, este trabalho propõe uma formulação em PLI para a versão do problema MIN-STATION considerada nesse estudo e uma segunda formulação para uma generalização deste problema. A primeira, denominada formulação base, utiliza um modelo de fluxo em um dígrafo de alcance, no qual os arcos representam deslocamentos possíveis com uma única carga. A segunda formulação amplia essa modelagem ao considerar cenários mais gerais, com robôs de diferentes autonomias, custos de instalação e restrições de elegibilidade entre origens e destinos. Além disso, são apresentados experimentos computacionais preliminares nos quais a formulação generalizada é parametrizada para representar a versão base, permitindo comparar o comportamento computacional das duas formulações.

O restante deste trabalho está organizado da seguinte forma: a Seção 2 introduz a definição formal do problema, enquanto a Seção 3 detalha as formulações de PLI propostas. Os experimentos e a discussão dos resultados são apresentados na Seção 4. Por fim, a Seção 5 encerra o trabalho com as conclusões e sugestões para pesquisas futuras.

2. Definição do Problema

Considera-se um grafo simples, não direcionado e conexo que representa uma rede de transporte. Os vértices representam locais de interesse e as arestas indicam as conexões entre eles. Cada conexão possui um comprimento associado, que pode representar, por exemplo, distância física, tempo de viagem ou número de passos. Assim, a distância entre dois vértices é entendida como o menor comprimento necessário para ir de um ao outro, considerando todos os percursos possíveis na rede.

Existem dois grupos de vértices com a mesma quantidade de elementos: origens e destinos. O primeiro contém as posições de partida de m robôs e o segundo contém os locais que devem estar ocupados ao final do processo. Cada destino deve ser ocupado por exatamente um robô. Como os robôs são indistinguíveis, qualquer robô pode terminar em qualquer destino. Os vértices que não pertencem a esses grupos são considerados intermediários e podem receber estações de recarga.

Adota-se uma autonomia comum a todos os robôs, definida por um limite de distância que pode ser percorrida entre recargas. No início, a bateria está em sua capacidade máxima e, sempre que um robô visita um vértice com estação instalada, ela é totalmente restaurada. Um caminho é considerado viável quando, ao longo do trajeto, a distância percorrida desde a última recarga não ultrapassa esse limite.

O objetivo é decidir onde instalar as estações de recarga nos vértices intermediários e definir m rotas viáveis que conduzam os robôs das origens aos destinos, de modo que cada origem seja utilizada por um único robô e cada destino seja atendido exatamente uma vez, minimizando o total de estações necessárias.

2.1. Definição formal

• **Entrada:** $\langle G, S, T, r \rangle$, onde:

- $G = (V, E)$ é um grafo simples, não direcionado e conexo, associado a uma função de comprimento $\ell : E \rightarrow \mathbb{R}_{>0}$.
- $S \subset V$ é o conjunto de vértices de partida de m robôs.
- $T \subset V$ é o conjunto de vértices de destino, com $|S| = |T| = m$.
- $r \in \mathbb{R}_{>0}$ é a autonomia de cada robô.
- $V_I := V \setminus (S \cup T)$ representa os vértices intermediários elegíveis para receber estações.

Para quaisquer $u, v \in V$, denota-se por $d(u, v)$ a distância entre u e v em G , definida como o comprimento da rota mais curta que liga esses vértices.

- **Solução:**

- Escolher um conjunto de instalação $C \subseteq V_I$, de forma tal que:
 - * Existem m rotas que conduzem os robôs das origens em S aos destinos em T , de modo que cada origem seja utilizada exatamente uma vez e cada destino seja ocupado exatamente uma vez.
 - * Ao longo do trajeto de cada rota, a distância entre pontos consecutivos de recarga não excede r . Consideram-se como pontos de recarga a partida do robô, quaisquer vértices em C visitados e o destino correspondente.

- **Objetivo:** Minimizar a cardinalidade do conjunto C .

2.2. Generalização considerada

A definição anterior serve como base, mas este trabalho propõe, também, uma generalização que traz o problema para um cenário mais real. Nela, incluímos três novos fatores: custos de instalação que variam conforme o local, robôs com autonomias individuais e restrições de elegibilidade entre origens e destinos.

Nessa variante, cada vértice candidato v tem seu próprio custo de instalação $c_v \geq 0$. A autonomia deixa de ser padrão e passa a ser $r_s \in \mathbb{Z}_{>0}$ para o robô de cada origem s . Por fim, usamos o parâmetro $e_{s,t} \in \{0, 1\}$ para definir se a conexão entre uma origem s e um destino t é permitida ou não.

Com esses elementos, o objetivo deixa de ser apenas minimizar a quantidade de estações instaladas e passa a minimizar o custo total de instalação, respeitando as autonomias individuais e as restrições de elegibilidade.

3. Formulações

Nesta seção, são apresentadas duas formulações em PLI. A primeira, denominada formulação base, modela a versão base do MIN-STATION considerada neste trabalho. A segunda formulação modela a generalização apresentada na Seção 2.2, incorporando custos de instalação, autonomias distintas e restrições de elegibilidade entre origens e destinos. Para viabilizar a comparação entre as formulações, o modelo estendido foi parametrizado para reproduzir o comportamento da versão base, conforme discutido na Seção 4.2.1.

3.1. Formulação base

Esta formulação aborda o problema MIN-STATION como um modelo de PLI baseado em fluxo. Em vez de rastrear cada robô individualmente, o modelo foca no fluxo total de robôs que percorre o grafo.

Para tratar a restrição de autonomia r , a abordagem evita monitorar o consumo de energia em cada aresta do grafo original G . Em vez disso, a estratégia consiste em pré-calcular, para cada vértice $u \in V$, os vértices que podem ser alcançados a partir de u por um caminho de comprimento total não superior a r . Esse pré-processamento pode ser realizado executando o algoritmo de Dijkstra a partir de cada vértice, interrompendo a exploração de caminhos cuja distância ultrapasse r . Considerando $n = |V|$ e $m = |E|$, são realizadas n execuções, com complexidade de tempo $O(n(n+m) \log n)$ no pior caso. As conexões identificadas nesse processo são então representadas em uma nova estrutura: um dígrafo de alcance (V, A_r) .

Nesse dígrafo, o conjunto de arcos A_r representa todos os saltos viáveis. Um salto de um vértice u para um vértice v é considerado viável se a distância do caminho mais curto entre eles em G , denotada por $d(u, v)$, não excede a autonomia r . Formalmente, o conjunto de arcos admissíveis é definido como:

$$A_r = \{(u, v) \in V \times V : u \neq v, d(u, v) \leq r\}$$

Em outras palavras, cada arco em A_r funciona como uma rota que um robô pode percorrer sem precisar recarregar no meio do caminho. Com o dígrafo de alcance definido, o problema se resume a decidir onde instalar estações e como rotear o fluxo de robôs. Para modelar essas decisões, são definidas as variáveis:

- $y_v \in \{0, 1\}$: indica se uma estação é instalada em $v \in V_I$.
- $f_{u,v} \in \mathbb{Z}_{\geq 0}$: fluxo agregado (número de robôs) que percorre o salto $u \rightarrow v$, para todo $(u, v) \in A_r$.

Função objetivo

O objetivo é minimizar o número total de estações instaladas:

$$\min \sum_{v \in V_I} y_v. \quad (1)$$

Restrições

Fluxo em Fontes e Sumidouros

Saída nas origens. De cada origem $s \in S$ sai exatamente uma unidade de fluxo:

$$\sum_{v: (s,v) \in A_r} f_{s,v} = 1 \quad \forall s \in S \quad (2)$$

Entrada nas origens. Nada entra nas origens:

$$\sum_{u: (u,s) \in A_r} f_{u,s} = 0 \quad \forall s \in S \quad (3)$$

Entrada nos destinos. Em cada destino $t \in T$ chega exatamente uma unidade de fluxo:

$$\sum_{u: (u,t) \in A_r} f_{u,t} = 1 \quad \forall t \in T \quad (4)$$

Saída nos destinos. Nada sai dos destinos:

$$\sum_{w: (t,w) \in A_r} f_{t,w} = 0 \quad \forall t \in T \quad (5)$$

Conservação de Fluxo em Vértices Intermediários

Garante-se a continuidade do fluxo em todo vértice intermediário $v \in V_I$.

$$\sum_{u: (u,v) \in A_r} f_{u,v} = \sum_{w: (v,w) \in A_r} f_{v,w} \quad \forall v \in V_I \quad (6)$$

Ativação por Instalação

O fluxo agregado só pode atravessar vértices intermediários com estação instalada ($y_v = 1$). Usa-se $|S|$ como limitante superior seguro para o total de fluxo.

$$\sum_{u: (u,v) \in A_r} f_{u,v} \leq |S| y_v \quad \forall v \in V_I \quad (7)$$

Assim, a formulação base é composta pela função objetivo (1), pelas restrições de fluxo nas origens e destinos (2)–(5), pela restrição de conservação de fluxo nos vértices intermediários (6) e pela restrição de ativação por instalação (7). Em conjunto, essas restrições garantem que uma unidade de fluxo saia de cada origem, que uma unidade de fluxo chegue a cada destino e que o fluxo só atravessasse vértices intermediários nos quais uma estação de recarga tenha sido instalada.

3.2. Formulação estendida

A formulação estendida aplica a generalização da Seção 2.2. Ao contrário do modelo base, que utiliza fluxo agregado, esta versão trata o deslocamento de cada robô individualmente e estabelece o pareamento entre origens e destinos.

Como a autonomia pode variar entre os robôs, define-se um conjunto de arcos admissíveis específico para cada origem $s \in S$:

$$A_{r_s} = \{(u, v) \in V \times V : u \neq v, d(u, v) \leq r_s\}. \quad (8)$$

As variáveis de decisão são:

- $y_v \in \{0, 1\}$: indica se uma estação é instalada no vértice $v \in V_I$;
- $x_{u,v,s} \in \{0, 1\}$: indica se o robô que parte da origem $s \in S$ percorre o salto $u \rightarrow v$, com $(u, v) \in A_{r_s}$;
- $p_{s,t} \in \{0, 1\}$: indica se a origem $s \in S$ é pareada com o destino $t \in T$.

$$\min \sum_{v \in V_I} c_v y_v \quad (9)$$

$$\text{sujeito a} \quad \sum_{t \in T: e_{s,t}=1} p_{s,t} = 1 \quad \forall s \in S \quad (10)$$

$$\sum_{s \in S: e_{s,t}=1} p_{s,t} = 1 \quad \forall t \in T \quad (11)$$

$$\sum_{v: (s,v) \in A_{r_s}} x_{s,v,s} = 1 \quad \forall s \in S \quad (12)$$

$$\sum_{u: (u,t) \in A_{r_s}} x_{u,t,s} = p_{s,t} \quad \forall s \in S, \forall t \in T \text{ com } e_{s,t} = 1 \quad (13)$$

$$\sum_{u: (u,s) \in A_{r_s}} x_{u,s,s} = 0 \quad \forall s \in S \quad (14)$$

$$\sum_{v: (t,v) \in A_{r_s}} x_{t,v,s} = 0 \quad \forall s \in S, \forall t \in T \quad (15)$$

$$\sum_{u: (u,v) \in A_{rs}} x_{u,v,s} = \sum_{w: (v,w) \in A_{rs}} x_{v,w,s} \quad \forall s \in S, \forall v \in V_I \quad (16)$$

$$\sum_{u: (u,v) \in A_{rs}} x_{u,v,s} \leq y_v \quad \forall s \in S, \forall v \in V_I \quad (17)$$

A função objetivo (9) minimiza o custo total de instalação das estações. As restrições (10) e (11) garantem que cada origem seja pareada com exatamente um destino e que cada destino receba um único robô.

A restrição (12) garante que cada robô saia de sua origem inicial. A restrição (13) vincula o destino final ao pareamento realizado: se $p_{s,t} = 1$, o robô que parte de s deve terminar o percurso em t ; caso contrário ($p_{s,t} = 0$), o robô não pode finalizar seu trajeto nesse destino.

As restrições (14) a (15) controlam o fluxo nas origens e destinos para evitar caminhos inválidos. Especificamente, elas impedem a entrada de robôs em qualquer origem, a saída de uma origem que não pertença ao próprio robô e a saída de um destino após a sua chegada.

Por fim, a restrição (16) define a conservação de fluxo nos vértices intermediários, garantindo a continuidade das rotas. A restrição (17) condiciona a passagem por um vértice intermediário à instalação de uma estação. Assim, se $y_v = 0$, o trânsito pelo vértice v é proibido; se $y_v = 1$, o vértice torna-se disponível para transição e recarga.

4. Experimentos Computacionais

Esta seção descreve as instâncias utilizadas, a configuração computacional adotada e as métricas consideradas para avaliar o desempenho das formulações propostas para o problema MIN-STATION. O código-fonte, as instâncias utilizadas e os scripts de execução estão disponíveis em um repositório no Github¹. Nos experimentos, foram utilizados os parâmetros padrão do Gurobi, exceto pelo limite de tempo de execução definido neste trabalho.

4.1. Instâncias

As instâncias utilizadas nos experimentos, e resumidas na Tabela 1, foram geradas a partir de subgrafos de tamanho controlado que foram extraídos de redes disponíveis no repositório *Transportation Network Test Problems* (TNTP)².

Durante o processo de geração das instâncias, foram extraídos subgrafos conexos a partir das redes originais, com o objetivo de obter grafos de tamanhos variados. Em seguida, foram definidos os conjuntos de origens S e destinos T , garantindo que fossem disjuntos e balanceados, isto é, $|S| = |T|$. Por fim, o parâmetro de autonomia r foi definido de forma que os robôs pudessem chegar aos destinos respeitando a distância máxima r entre recargas.

4.2. Configuração experimental

Os modelos matemáticos foram implementados usando o Python 3.12 e o solver Gurobi Optimizer, versão 12.0.3. Os experimentos foram executados em um computador com processador Intel Core i5-13420H, 32 GB de memória RAM e sistema operacional Linux Mint 22.1.

Cada instância foi executada com um tempo limite de 3600 segundos. Além disso, as formulações foram avaliadas com variações de valores do parâmetro de autonomia r , visando investigar o impacto deste sobre a dificuldade computacional do problema.

¹Disponível em: <https://github.com/ElielLucas/min-station>

²Disponível em: <https://github.com/bstabler/TransportationNetworks>

Tabela 1: Resumo das instâncias utilizadas nos experimentos.

Instância	$ V $	$ E $	$ S = T $	$ V_I $
Anaheim_1	416	914	19	378
Chicago_1	400	1130	5	390
Chicago_2	400	1130	10	380
Chicago_3	400	1130	15	370
Philadelphia_1	800	2404	5	790
Philadelphia_2	800	2404	25	750
Philadelphia_3	800	2404	39	722
Barcelona_1	930	2522	15	900
Barcelona_2	930	2522	25	880
Barcelona_3	930	2522	50	830

4.2.1. Comparabilidade das formulações

Para permitir uma comparação direta entre as formulações, a formulação estendida foi parametrizada para reproduzir o mesmo problema modelado pela formulação base. Para isso, foram usados custos unitários de instalação, autonomia comum para todos os robôs e elegibilidade total entre origens e destinos:

$$\begin{aligned}
 c_v &= 1, \quad \forall v \in V_I, \\
 r_s &= r, \quad \forall s \in S, \\
 e_{s,t} &= 1, \quad \forall s \in S, \forall t \in T.
 \end{aligned}$$

4.3. Métricas de avaliação

O desempenho das formulações foi avaliado pelo limite superior (LS), correspondente à melhor solução inteira encontrada, pelo limite inferior (LI), correspondente ao melhor limitante dual, pelo gap de otimalidade, calculado por $GAP = \frac{LS-LI}{|LS|} \times 100\%$ [Gurobi Optimization, LLC], pelo número de nós explorados na árvore de *branch-and-cut* e pelo tempo de execução até a obtenção da solução ótima ou o limite de tempo. Além disso, foram registrados o número de variáveis (Vars.) e de restrições (Restr.) do modelo gerado, utilizados para comparar o tamanho das formulações.

4.4. Resultados e discussão

Nesta seção, são analisados os resultados obtidos a partir da execução das formulações *Baseline* (BASE) e Estendida (EXT). A análise é estruturada em três partes: primeiro, um panorama geral comparando o desempenho das duas formulações. Em seguida, uma análise sobre o impacto do parâmetro de autonomia (r). E, por fim, uma discussão sobre o comportamento de convergência dos modelos.

Análise Comparativa das Formulações

Os resultados de todas as instâncias estão consolidados na Tabela 2. Por meio desta, vê-se que o modelo *Baseline* atinge gap 0% ou fecha o gap de forma significativa na maioria dos casos. Em contraste, o modelo Estendido se mostra mais difícil de resolver. Visto que, embora encontre, na maior parte dos casos, soluções de qualidade similar (valores de LS próximos ou iguais aos do *Baseline*), apresenta maior dificuldade na obtenção e melhoria do limitante dual. Em muitas instâncias o modelo atinge o tempo limite com um gap elevado e uma contagem de nós muito baixa. Esse comportamento está associado ao maior porte da formulação Estendida, que apresenta um número significativamente maior de variáveis e restrições em relação ao *Baseline*, aumentando o esforço computacional necessário para o processamento do modelo.

Tabela 2: Resultados consolidados: *Baseline* vs. Estendido.

Instância	r	Modelo <i>Baseline</i> (BASE)							Modelo Estendido (EXT)						
		LS	LI	Gap(%)	Nós	Tempo(s)	Vars.	Restr.	LS	LI	Gap(%)	Nós	Tempo(s)	Vars.	Restr.
Anaheim_1	4	28	28	0.00	44573	283.96	5887	832	28	22	21.43	1341	3600.98	105410	15846
Anaheim_1	3	45	45	0.00	89752	493.28	3602	832	45	39	13.33	2404	3600.79	61995	15846
Anaheim_1	2	80	80	0.00	115763	419.42	2039	832	80	72	10.00	13833	3600.44	32298	15846
Chicago_1	8	9	9	0.00	1	4.82	13105	800	9	9	0.00	1	12.79	63990	4010
Chicago_1	7	11	11	0.00	1	5.60	10568	800	11	11	0.00	278	68.40	51305	4010
Chicago_2	9	10	10	0.00	20833	320.26	15851	800	10	8	20.00	2658	3600.95	155190	8020
Chicago_2	8	12	12	0.00	1	28.24	13095	800	12	10	16.67	2684	3601.00	127630	8020
Chicago_2	7	16	16	0.00	18916	154.74	10558	800	16	12	25.00	2903	3600.84	102260	8020
Chicago_3	10	9	9	0.00	45613	1365.14	18819	800	9	6	33.33	620	3601.97	277330	12030
Chicago_3	9	11	11	0.00	2517	155.74	15841	800	11	7	36.36	641	3603.75	232660	12030
Chicago_3	8	13	13	0.00	4335	91.54	13085	800	13	10	23.08	1399	3601.85	191320	12030
Chicago_3	7	17	17	0.00	64617	398.98	10548	800	17	12	29.41	1960	3602.74	153265	12030
Philadelphia_1	8	6	6	0.00	2330	459.05	60815	1600	6	6	0.00	176	778.27	300940	8010
Philadelphia_1	7	9	7	22.22	36569	3600.56	47295	1600	9	7	22.22	817	3601.91	233340	8010
Philadelphia_1	6	11	9	18.18	43021	3600.46	35489	1600	11	11	0.00	4453	3516.18	174310	8010
Philadelphia_1	5	14	11	21.43	56343	3600.43	25492	1600	14	9	35.71	1110	3601.15	124325	8010
Philadelphia_1	4	17	16	5.88	86976	3600.39	17210	1600	17	16	5.88	4784	3600.86	82915	8010
Philadelphia_1	3	26	22	15.38	96218	3600.12	10627	1600	26	18	30.77	2476	3600.55	50000	8010
Philadelphia_1	2	41	39	4.88	152629	3600.19	5805	1600	41	31	24.39	3318	3600.33	25890	8010
Philadelphia_2	8	7	7	0.00	1723	325.15	60775	1600	8	6	25.00	1	3617.15	1502000	40050
Philadelphia_2	7	10	9	10.00	55571	3600.73	47255	1600	10	6	40.00	1	3607.87	1164000	40050
Philadelphia_2	6	14	14	0.00	36431	1850.29	35449	1600	14	9	35.71	1	3606.11	868850	40050
Philadelphia_2	5	20	17	15.00	42839	3600.49	25452	1600	22	13	40.91	1	3604.54	618925	40050
Philadelphia_2	4	29	26	10.34	48604	3600.31	17170	1600	33	20	39.39	1	3603.17	411875	40050
Philadelphia_2	3	47	41	12.77	103004	3600.22	10587	1600	47	32	31.91	2	3602.39	247300	40050
Philadelphia_3	5	22	20	9.09	41872	3600.26	25424	1600	24	13	45.83	1	3606.32	965621	62478
Philadelphia_3	4	37	33	10.81	61305	3600.32	17142	1600	43	21	51.16	1	3605.21	642623	62478
Philadelphia_3	3	60	53	11.67	90573	3600.30	10559	1600	65	37	43.08	1	3603.30	385886	62478
Barcelona_1	5	15	15	0.00	7340	491.24	33548	1860	16	10	37.50	11	3606.97	490845	27930
Barcelona_1	4	20	20	0.00	30611	868.71	21413	1860	20	15	25.00	76	3602.51	308820	27930
Barcelona_2	5	16	16	0.00	18724	920.87	33528	1860	16	11	31.25	1	3610.15	817705	46550
Barcelona_2	4	23	23	0.00	3694	370.38	21393	1860	23	18	21.74	8	3604.05	514330	46550
Barcelona_3	6	14	11	21.43	16302	3600.45	49183	1860	795	0	100.00	1	3621.42	2420980	93100
Barcelona_3	5	20	15	25.00	32711	3600.49	33478	1860	23	10	56.52	1	3610.91	1635730	93100
Barcelona_3	4	32	27	15.62	38193	3600.37	21343	1860	37	18	51.35	1	3607.60	1028980	93100
Barcelona_3	3	55	50	9.09	89016	3600.27	12114	1860	63	35	44.44	1	3604.66	567530	93100

Impacto da Autonomia (r)

À medida que r diminui, o problema se torna mais restrito, exigindo um número maior de estações (LS mais alto). Por outro lado, valores menores de r também reduzem o número de arcos no dígrafo de alcance e, consequentemente, o número de variáveis dos modelos. Assim, a redução de r aumenta a necessidade de estações, mas também pode diminuir o tamanho do problema a ser resolvido. Esse efeito é mais perceptível no modelo Estendido, pois o aumento do número de arcos provoca um aumento muito maior no seu número de variáveis.

Análise de Convergência

Esta seção apresenta os perfis de convergência para duas instâncias representativas. Os gráficos a seguir mostram a evolução dos limitantes superior (LS) e inferior (LI) ao longo do tempo de execução.

Análise da Instância Anaheim_1 ($r = 2$). Na Figura 1, o modelo *Baseline* demonstra um bom comportamento. A solução ótima (LS = 80) é encontrada nos primeiros segundos da execução, e o limitante inferior (LI) progride até provar a otimalidade. Em contraste, o modelo *Estendido*, embora também encontre o LS ótimo rapidamente, demonstra dificuldade com o limitante dual, encerrando a execução com gap de 10%.

Análise da Instância Barcelona_2 ($r = 4$). A situação piora na instância de Barcelona (Figura 2). O modelo *Baseline* novamente resolve o problema de forma eficiente. Já o modelo Estendido demora mais para encontrar uma boa *solução viável* e, embora alcance o mesmo $LS = 23$, seu limitante inferior (LI) progride até 18 e permanece praticamente sem avanço durante o restante da execução, encerrando com gap de 21,74%.




Figura 1: Evolução dos limitantes para a instância Anaheim_1 ($r = 2$): Baseline (acima) e Estendido (abaixo).

5. Conclusão

Os experimentos mostram que a formulação base apresenta bom desempenho como método exato para a versão do MIN-STATION considerada neste trabalho. A análise indica que essa formulação foi capaz de encontrar boas soluções e, em diversas instâncias, provar otimalidade dentro do limite de tempo considerado.

Por outro lado, a formulação estendida apresentou maior dificuldade computacional. Embora essa formulação permita representar custos de instalação, autonomias distintas e restrições de elegibilidade entre origens e destinos, nos experimentos ela foi parametrizada para representar o caso base, considerando custos unitários, autonomia comum para todos os robôs e elegibilidade completa entre origens e destinos. Essa parametrização foi adotada para permitir a comparação direta entre as formulações, mas também pode introduzir muitas simetrias no modelo, uma vez que diferentes pareamentos e rotas podem representar soluções equivalentes.




Figura 2: Evolução dos limitantes para a instância *Barcelona_2* ($r = 4$), $|S| = 25$: Baseline (acima) e Estendido (abaixo).

Os resultados indicam que a estrutura desagregada da formulação estendida resulta em um modelo maior, com mais variáveis e restrições. Esse aumento dificulta o processamento do modelo e a melhoria dos limitantes ao longo da execução, resultando, em diversas instâncias, em gaps de otimalidade mais elevados. Dessa forma, a dificuldade observada não deve ser interpretada apenas como consequência da generalização do problema, mas também da estrutura da formulação e da presença de soluções simétricas no caso homogêneo avaliado.

Mesmo na formulação base, a qualidade da relaxação linear ainda necessita de atenção. As restrições de ativação dependem de um parâmetro Big-M ($|S|$) e, mesmo que esse limitante seja válido, ele pode enfraquecer a relaxação linear do modelo, pois permite que uma fração da variável de instalação y_v seja suficiente para viabilizar a passagem de fluxo por um vértice intermediário.

Como próximos passos, é possível focar no fortalecimento das formulações propostas. Isso inclui a investigação de estratégias de pré-processamento, o desenvolvimento de planos de corte, a inclusão de restrições de quebra de simetria e a exploração de formulações alternativas que proporcionem limitantes mais fortes e maior eficiência na resolução de instâncias grandes. Além disso, a formulação estendida deve ser avaliada em instâncias que explorem efetivamente sua generalidade, considerando custos heterogêneos, autonomias distintas e restrições de elegibilidade.

Referências

- Antonyshyn, L., Silveira, J., Givigi, S., e Marshall, J. (2023). Multiple mobile robot task and motion planning: A survey. *ACM Computing Surveys*, 55(10):1–35. URL <https://doi.org/10.1145/3564696>.
- Castro-Gama, M. e Hassink-Mulder, Y. (2023). Optimal charging station placement for autonomous robots in drinking water networks. *Journal of Hydroinformatics*, 25(6):2253–2267. URL <https://doi.org/10.2166/hydro.2023.040>.
- Das, A. K. (2025). Charging station placement for limited energy robots. In Gaur, D. e Mathew, R., editors, *Algorithms and Discrete Applied Mathematics (CALDAM 2025)*, volume 15536 of *Lecture Notes in Computer Science*, p. 97–108, Cham. Springer. URL https://link.springer.com/chapter/10.1007/978-3-031-83438-7_9.
- Gurobi Optimization, LLC. What is the MIPGap? <https://support.gurobi.com/hc/en-us/articles/8265539575953-What-is-the-MIPGap>. Acessado em: 28-09-2025.
- Kundu, T. e Saha, I. (2018). Charging station placement for indoor robotic applications. In *2018 IEEE International Conference on Robotics and Automation (ICRA)*, p. 3029–3036, Brisbane, QLD, Australia. IEEE. URL <https://doi.org/10.1109/ICRA.2018.8461006>.
- Kundu, T. e Saha, I. (2023). Approximation algorithms for charging station placement for mobile robots. In *2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, p. 4770–4776, Detroit, MI, USA. IEEE. URL <https://doi.org/10.1109/IROS55552.2023.10341361>.
- Strimel, G. P. e Veloso, M. M. (2014). Coverage planning with finite resources. In *2014 IEEE/RSJ International Conference on Intelligent Robots and Systems*, p. 2950–2956, Chicago, IL, USA. IEEE. URL <https://doi.org/10.1109/IROS.2014.6942969>.
- Vichitkunakorn, P., Emde, S., Masae, M., Glock, C. H., e Grosse, E. H. (2024). Locating charging stations and routing drones for efficient automated stocktaking. *European Journal of Operational Research*, 316:1129–1145. URL <https://doi.org/10.1016/j.ejor.2024.03.002>.